TransChromBP 论文轮廓

连接 AlphaGenome 与 ChromBPNet 的 ATAC 专用长程建模研究

作者待定

主线重构稿，2026 年 3 月 15 日

摘要

本文不再把 TransChromBP 仅仅定义为“带 Transformer 的 ChromBPNet 变体”，也不把它写成一次以数据处理技巧为中心的工程调参工作。新的论文主线是：在碱基分辨率 ATAC-seq profile prediction 中，AlphaGenome 式的长程建模与蒸馏范式，和 ChromBPNet 式的 bias factorization，究竟是互补、冗余，还是彼此牵制。基于这一问题，本文计划提出一个旗舰模型：在固定的 ATAC 专用数据语义下，将卷积局部编码、compressed-token Transformer、ChromBPNet 风格的 bias branch，以及 teacher-student distillation 组合到同一框架中。论文的目标有两层。第一，给出一个在当前 benchmark 上足够强、可作为 SOTA 候选的主模型。第二，围绕该主模型系统拆解三个机制轴：Transformer 是否真正提供长程信息，distillation 是否把 teacher 的长程知识有效迁移给 student，以及 bias factorization 在存在前两者时是否仍然必要。当前已有实验结果（原始 `bias_pretrain -> main_learnable` 主线优于 baseline，混合数据语义更像负对照）将作为论文的起点和约束条件，而不再作为论文的核心问题本身。

目录

1 论文定位 **1**
- 1.1 核心 gap . . . 1
- 1.2 论文主张 . . . 2
- 1.3 论文必须同时做到两件事 . . . 2
- 1.4 不应宣称的内容 . . . 2

2 核心科学问题 **2**

3 任务定义与固定前提 **3**
- 3.1 固定的数据语义，不再当主变量 . . . 3
- 3.2 为什么当前证据足以固定数据语义 . . . 3

4 方法总览 **3**
- 4.1 旗舰模型 . . . 3
- 4.2 为什么需要 teacher / student . . . 4
- 4.3 蒸馏对象 . . . 4
- 4.4 Bias-aware fusion . . . 4

5 实验设计 **4**
5.1 Benchmark 组织 4
5.2 主结果表应包含哪些模型 5
5.3 机制实验矩阵 5
5.4 Teacher 设计 5
5.5 解释与分层分析 6

6 当前已有证据如何为论文服务 **6**
6.1 已建立的事实 6
6.2 这些事实意味着什么 6

7 预期贡献写法 **6**

8 写作边界与风险控制 **7**
8.1 边界 7
8.2 最大风险 7

1 论文定位

1.1 核心 gap

本文要填补的 gap 不是简单的“ChromBPNet 上下文较短，AlphaGenome 上下文较长”，而是：

> 当前 ATAC 碱基分辨率建模缺少一个清晰的中间层研究框架，能够同时回答长程表征、知识蒸馏和实验偏差分解三者在同一任务中的作用关系。

ChromBPNet 给出了很强的 ATAC-specific task definition，但它的经典主线并不围绕长程上下文和蒸馏展开。AlphaGenome 展示了更完整的长程建模和蒸馏范式，但它并不是为 ATAC bias-aware profile prediction 定义的。TransChromBP 的目标就是把这两边真正可对接的部分接起来。

1.2 论文主张

论文主张固定为一句话：

> 对于碱基分辨率的 ATAC-seq profile prediction，最有效的设计点不是单纯更长的上下文，也不是去掉 assay-specific inductive bias 的统一 foundation-style 方案，而是 Transformer、distillation 与 ChromBPNet-style bias factorization 的受控结合。

1.3 论文必须同时做到两件事

这篇论文不能只做机制分析，也不能只做“一个更强模型”。必须同时完成：

1. 提出一个足够强的旗舰模型，作为 benchmark 上的主结果候选；
2. 围绕这一旗舰模型，拆解 Transformer、distillation 与 bias factorization 各自贡献了什么。

1.4 不应宣称的内容

为保证论文口径稳健，正文中应避免以下过度宣称：

- 不把本文写成一个多模态 foundation model；
- 不宣称全面覆盖 AlphaGenome 的任务范围；
- 不把当前论文主线仍然表述成“数据处理是否正确”的争论；
- 不把单一 benchmark 上的提升泛化为“任何功能基因组任务都更强”。

2 核心科学问题

正文中的研究问题建议明确写成四条：

1. **RQ1:** 对 ATAC profile prediction 而言，Transformer 的收益是否真的来自长程上下文，而不是单纯更大容量。
2. **RQ2:** Distillation 能否把长上下文 teacher 的知识稳定迁移到更轻的 student，且不破坏 profile 级别的精细预测。
3. **RQ3:** 在引入 Transformer 与 distillation 之后，ChromBPNet-style bias factorization 仍然是否必要；如果必要，它更适合 fixed 还是 learnable 的融合方式。
4. **RQ4:** 三者之间是加性关系、替代关系，还是存在显著交互项。

这四个问题应成为整篇论文实验设计和结论组织的主轴。

3 任务定义与固定前提

3.1 固定的数据语义，不再当主变量

数据处理在这篇论文里仍然重要，但不再作为主战场反复摇摆。根据当前已经完成的审计，后续实验应固定在一套明确的 ATAC 专用语义上：

- 使用 shifted unstranded insertion bigWig 作为 canonical signal；
- peaks 使用 summit-centered windows；
- nonpeaks 使用 GC-matched negatives；
- bias 预训练采用 nonpeak-only、no jitter；
- main 训练采用 peak-centric supervision 和较低 nonpeak exposure；
- 训练期使用 reverse-complement augmentation，验证和测试保持确定性；
- count loss weight 采用自动标定而非固定常数。

这部分应在方法节中被定义为 *fixed task semantics*，而不是新的实验轴。

3.2 为什么当前证据足以固定数据语义

这一点需要在文中简要交代，但不宜喧宾夺主。我们已经知道：

- 原始 `bias_pretrain -> main_learnable` 主线在 held-out test 上优于 baseline；
- 把多项 ChromBPNet / AlphaGenome 启发的改动整包绑成 `hybrid_data` 并没有带来更稳的结果；
- 因此，数据语义应被视为固定约束条件，而不是论文主角。

4 方法总览

4.1 旗舰模型

旗舰模型建议定义为：

> **Teacher-Student TransChromBP**：卷积局部特征提取 + compressed-token Transformer 长程编码 + ChromBPNet-style bias branch + profile/count 双头 + knowledge distillation。

它至少应包含以下组成：

- 卷积 stem：负责 motif 级别与近邻局部模式；
- 主干 Transformer：负责较长距离的序列依赖；
- bias branch：负责实验偏差相关信号；
- fusion 模块：负责把 debiased prediction 与 bias correction 组合成 full prediction；
- teacher/student 结构：teacher 使用更长上下文或更大容量，student 作为可部署版本。

4.2 为什么需要 teacher / student

如果只引入 Transformer 而没有蒸馏，论文叙事很容易退化成“更大的模型更强”。加入 teacher-student 结构后，才能把问题变成：

- teacher 是否真的学到了更有价值的长程表示；
- student 是否能够继承这些表示；
- 这种继承是否改变了 bias branch 的作用。

4.3 蒸馏对象

蒸馏目标建议至少覆盖两层：

1. **输出蒸馏**：profile logits / profile distribution 与 log-count；
2. **可选表征蒸馏**：主干中间 token 或 pooled representation。

正文中需要明确：蒸馏不是为了让 student 模仿 full signal 的一切细节，而是为了迁移 teacher 对长程调控上下文的有用信息。具体损失形式可在实验确定后再定稿。

4.4 Bias-aware fusion

这一部分是本文区别于一般 genomics Transformer 的关键。方法节要把下列对象写清楚：

- debiased profile / count；
- bias profile / count；
- full profile / count；
- bias 注入强度是 fixed 还是 learnable。

这一层如果写得清楚，后面的机制分析才有意义，因为我们可以分辨提升到底落在 regulatory branch 还是 bias branch。

5 实验设计

5.1 Benchmark 组织

主 benchmark 建议先固定在 tutorial 官方数据这一套任务完全匹配的数据上，再根据资源决定是否补一个第二数据集。重点不是做“大而全”的 benchmark，而是确保：

- baseline 明确；
- held-out split 明确；
- 评测指标和数据语义一致；
- 所有模型共享同一套 preprocessing / splits / metrics。

5.2 主结果表应包含哪些模型

主结果表建议围绕旗舰模型展开，而不是铺一个巨大组合矩阵。最小必要集合为：

1. ChromBPNet / 当前 conv-only 强基线；
2. Student TransChromBP（无蒸馏）；
3. Student TransChromBP（有蒸馏）；

4. Transformer + bias，无 distillation；
5. Transformer + distillation，无 bias；
6. Full flagship：Transformer + distillation + learnable bias；
7. Full flagship 的 fixed-bias 版本。

5.3 机制实验矩阵

围绕旗舰模型，只保留高价值实验轴：

- **Backbone axis**: conv-only vs conv+Transformer；
- **Training axis**: direct training vs distillation；
- **Bias axis**: no bias vs fixed bias vs learnable bias。

这三条轴可以回答最核心的科学问题，而且不会把实验资源耗在大量低价值组合上。

5.4 Teacher 设计

Teacher 不需要一开始就做成 AlphaGenome 级别的超大系统。更可行的设计是：

- 更长输入长度；
- 更大 hidden size 或更多 Transformer blocks；
- 与 student 共享相同的 ATAC-specific task semantics 和 bias formulation。

也就是说，teacher 的角色是“更强的同任务专家”，而不是“泛化到多模态的大一统模型”。

5.5 解释与分层分析

这篇论文不能只交一张主结果表。至少还需要以下分析：

- peak / nonpeak / difficult loci 分层表现；
- debiased output 与 full output 的分开评估；
- bias scale 与 fusion 行为的训练期轨迹；
- locus-level 轨道对照；
- 若资源允许，补 SHAP / motif / MoDISco；
- 若实验成熟，再加 ATAC-specific scorer，例如 center-mask 或 interval scorer。

6 当前已有证据如何为论文服务

6.1 已建立的事实

现有结果已经确定了三条对论文有用的事实：

1. 当前 `bias_pretrain -> main_learnable` 主线优于 baseline；
2. `hybrid_data` 更像一次数据语义负对照，而不是新主线；
3. bias-only sanity 显示 background bias 是可学对象，但不应在 peak 上承担主任务。

6.2 这些事实意味着什么

这些结果的作用不是让论文继续围绕“数据处理对不对”打转，而是提供三个约束：

- 以当前主线为可信起点；
- 把数据语义固定住，不再反复更改论文问题；
- 允许把研究重点上移到 Transformer、distillation 与 bias 机制的交互。

7 预期贡献写法

引言中的 contribution list 建议最终落成下面这种结构：

1. 提出一个 ATAC 专用旗舰模型，把长程 Transformer、teacher-student distillation 与 ChromBPNet-style bias factorization 纳入同一框架；
2. 在统一 benchmark 和固定数据语义下，建立一个更强的 base-resolution ATAC baseline，争取达到任务上的新 best result；
3. 系统回答三类机制问题：长程上下文是否有用、蒸馏是否有效、bias factorization 是否仍不可替代；
4. 通过分层和解释实验，说明模型提升落在 regulatory branch、bias branch，还是两者的交互上。

8 写作边界与风险控制

8.1 边界

需要始终守住三个边界：

- 这是 ATAC-specific paper，不是通用 genomics foundation model paper；
- 这是关于机制交互的 paper，不是单纯堆模型 paper；
- 这是一个由强主模型支撑的机制分析 paper，不是只有消融没有主结果的 paper。

8.2 最大风险

当前最主要的风险不是模型太弱，而是论文主线又被支线拉散。具体来说：

- 如果继续把数据处理当主变量，论文会失焦；
- 如果只做一个更大模型而不拆机制，论文会显得空；
- 如果只做机制分析而没有足够强的主模型，论文又会显得不够有冲击力。

因此，后续所有实验和写作都应回到同一个判断标准：

这项工作是否同时强化了旗舰模型和机制解释，而不是只增加了局部复杂度。