TransChromBP 阶段报告与论文主线重构

从 tutorial 结果汇总转向 Transformer、蒸馏与 bias 机制研究

项目工作文档

2026 年 3 月 15 日

摘要

本文档不再只是此前 tutorial 评估、hybrid_data 审计和推荐数据处理流程的汇编，而是在保留这些结果的同时，重新定义 TransChromBP 的论文主线。当前阶段已经建立了三条稳定结论：第一，原始 `bias_pretrain -> main_learnable` 主线在 held-out `test(chr1)` 上优于 tutorial baseline，可作为可信起点。第二，`hybrid_data` 更适合作为一次数据语义负对照，而不是新的默认训练线；它没有证明原始主线建立在明显错误的数据处理上。第三，ATAC 专用数据语义已经足够清晰，后续论文不应继续围绕它作为主战场。基于此，本文把研究目标正式收敛为一个更强的问题：在碱基分辨率 ATAC-seq profile prediction 中，AlphaGenome 式的 Transformer 长程建模与 teacher-student distillation，和 ChromBPNet 式的 bias factorization，究竟分别起什么作用、如何交互，以及能否在同一旗舰模型中共同带来更强结果。文中给出新的论文叙事、旗舰模型定义、实验矩阵、当前证据与固定约束条件，并保留后续复现所需的关键路径与资产目录。

1 为什么要重构主线

此前这条工作线已经积累了足够多的结果，但它们原本分散在三类叙事里：

- tutorial 主线是否优于 baseline；
- hybrid_data 是否说明数据处理存在明显偏差；
- 推荐数据处理流程应如何参考 ChromBPNet 和 AlphaGenome。

这些问题在项目推进早期都合理，但继续围绕它们组织全文，会使论文主线停留在“哪套 recipe 更像正确做法”的层面。当前证据已经足以让我们把这个阶段收束成前提条件，并把论文真正的问题上移到机制层：

> 在 ATAC 碱基分辨率建模中，Transformer、distillation 与 ChromBPNet-style bias factorization 的作用关系是什么。

2 当前已经确定的事实

2.1 事实一：当前主线优于 baseline

在独立 held-out `test(chr1)` 的 `62342` 个 region 上，原始主线与 tutorial baseline 的关键结果如下。

模型	overall r	overall JSD	peak r	peak JSD	nonpeak r	nonpeak JSD
`Orig best`	0.8416	0.4455	0.8207	0.3310	0.2276	0.5599
`Orig epoch20`	0.8347	0.4428	0.8141	0.3276	0.2359	0.5581
`Baseline epoch20`	0.8253	0.4536	0.8048	0.3437	0.1875	0.5635

表 1: 当前可信主线与 tutorial baseline 的 held-out test 对比。

这一定义了后续工作的固定起点：

- `Orig best` 代表 peak-first checkpoint；
- `Orig epoch20` 代表 overall-balanced checkpoint；
- tutorial baseline 不再是后续自研模型的首选主参照。

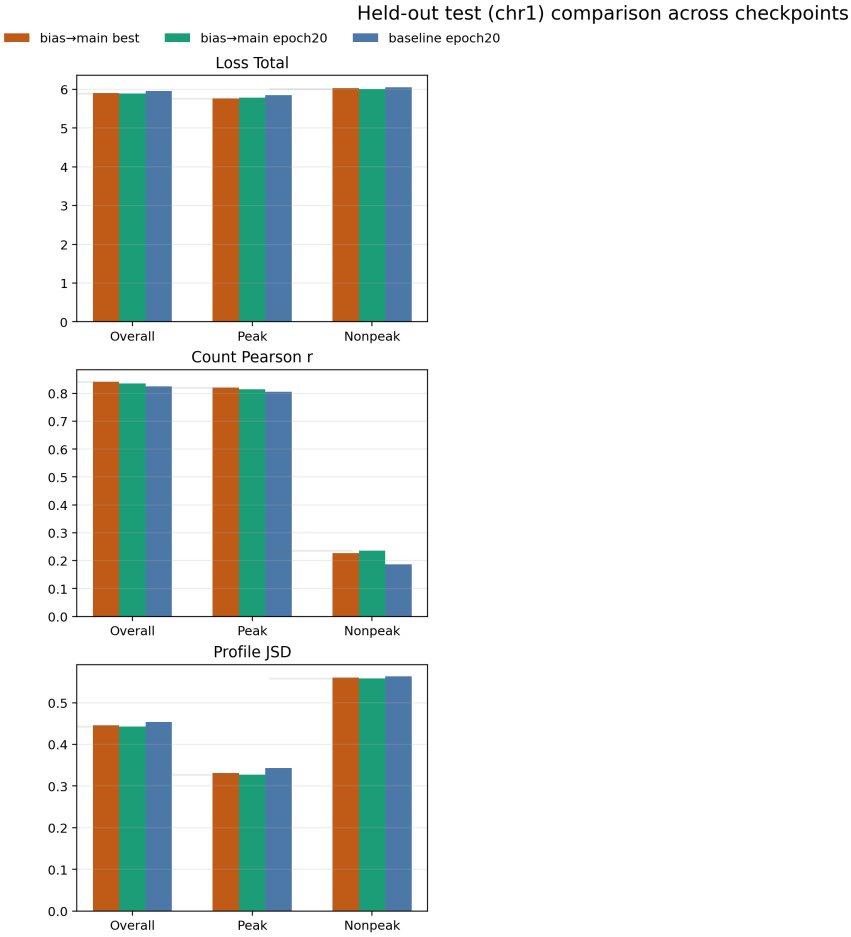

图 1: tutorial 主线与 baseline 的 held-out test 主指标对比。

2.2 事实二：hybrid_data 是一次有价值的负对照

`hybrid_data` 同时把 peak-only jitter、moderate nonpeak exposure、automatic count calibration 和在线 track-depth scaling 绑在了一起。它的结果更适合被理解为：

> “把多项来自 ChromBPNet 和 AlphaGenome 的启发整包照搬”并不会自然得到更好的 ATAC 主线。

在 full held-out test 上，它没有超过原始主线：

模型	overall r	overall JSD
`Orig epoch20`	0.8347	0.4428
`Hybrid learnable epoch20`	0.8000	0.4703
`Hybrid fixed epoch20`	0.7946	0.4687

表 2: 原始主线与 hybrid 主线在 full held-out test 上的总体对比。

在 trimmed test 上，排名也没有翻转。这个结果的意义不是“数据处理不重要”，而是：

- 当前项目没有被明显错误的数据语义卡死；
- 数据语义应作为固定前提，而不是继续做论文主角；
- 之后如果还改数据语义，应服务于模型主线，而不是重新定义问题。

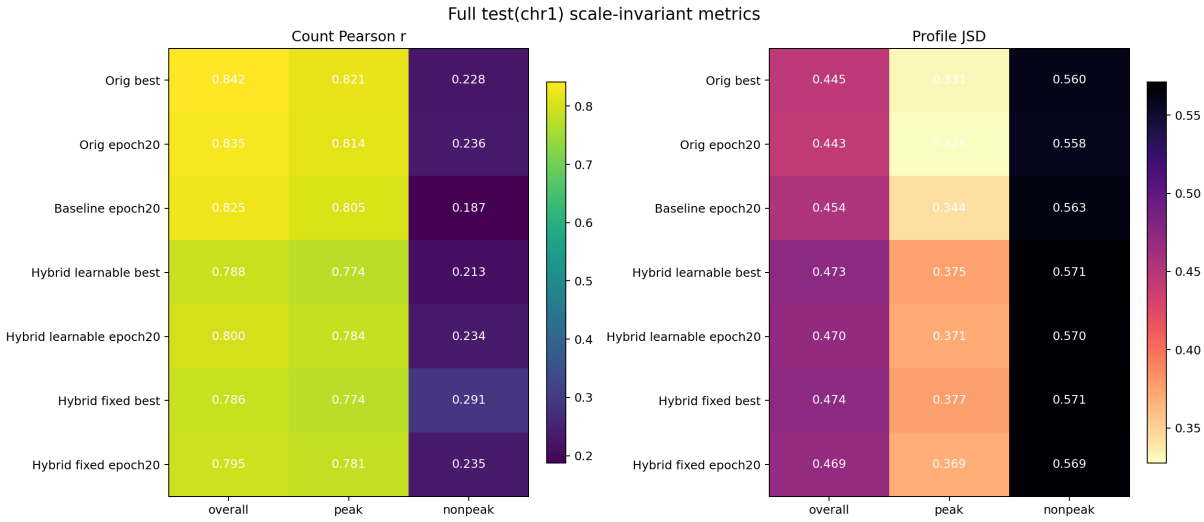

图 2: hybrid_data 审计结果热图。它说明当前更适合作为负对照，而不是新主线。

2.3 事实三：bias branch 具备独立职责

bias-only sanity check 已经说明，background bias 本身是可学对象，但不应在 peak 上承担主任务。

bias 模型	split	count r	profile JSD
`Orig bias_pretrain`	peak	-0.0089	0.4002
`Orig bias_pretrain`	nonpeak	0.4633	0.5685
`Hybrid bias_pretrain`	peak	0.1823	0.4016
`Hybrid bias_pretrain`	nonpeak	0.5412	0.5692

表 3: bias-only sanity check。

这为后续论文提供了一个重要边界：讨论 Transformer 和 distillation 之前，必须保留 bias-aware task formulation，否则很难判断模型到底是在学调控结构，还是在学实验偏差。

3 新的论文主线

3.1 从“recipe 争论”转向“机制交互”

新的论文主线不再是：

> 哪一种数据处理流程更像正确答案。

而是：

> 在 ATAC 碱基分辨率 profile prediction 中，Transformer 长程建模、teacher-student distillation 和 ChromBPNet-style bias factorization 究竟如何共同作用。

这一定义的好处是，它既保留了 ChromBPNet 的任务清晰性，也吸收了 AlphaGenome 真正值得学的部分，但不会把论文写成一个不必要的多模态 foundation model。

3.2 论文要同时完成两件事

这篇论文必须同时满足两个目标：

1. 提出一个足够强、可以冲击 benchmark 最优结果的旗舰模型；
2. 围绕这个旗舰模型，系统分析三类机制的作用与交互。

缺任何一个都不够。只有强模型没有机制解释，会显得像单纯堆模型；只有机制分析没有强主结果，又会显得像“因为模型不够强，所以只能做分析”。

4 旗舰模型定义

4.1 推荐的旗舰模型

论文主模型建议定义为：

> **Teacher-Student TransChromBP**：卷积 stem + compressed-token Transformer + ChromBPNet-style bias branch + profile/count 双头 + knowledge distillation。

它的核心组成应包括：

- 卷积 stem：负责 motif 级局部结构；
- 主干 Transformer：负责较长距离上下文；
- bias branch：负责 assay-specific 偏差；
- fusion 模块：组合 debiased prediction 与 bias correction；
- teacher / student：teacher 更强，student 更轻，二者共享相同任务语义。

4.2 为什么 distillation 是必须项

没有蒸馏时，Transformer 的收益很容易被读成“更大的模型更强”。一旦加入 teacher-student 结构，问题才会变得更有内容：

- teacher 学到的长程知识是否可迁移；
- 迁移后 student 的收益落在 profile、count、peak 还是 nonpeak；
- 蒸馏后的 student 是否仍然需要 bias factorization；
- 如果没有 bias branch，蒸馏收益会不会被错误地吸收到 bias 中。

4.3 固定前提：数据语义不再是主变量

后续实验都应建立在固定的 ATAC 专用数据语义上：

- shifted unstranded insertion bigWig；
- peak-centered windows；
- GC-matched nonpeaks；
- bias 预训练使用 nonpeak-only、no jitter；
- main 训练使用 peak-centric supervision 和较低 nonpeak exposure；
- train-only reverse-complement augmentation；
- automatic count loss calibration。

5 实验程序应如何围绕新主线组织

5.1 三条核心实验轴

后续实验不宜再铺一个很大的全因子矩阵，而应围绕三条主轴：

- **Backbone axis**: conv-only vs conv+Transformer；
- **Training axis**: direct training vs distillation；
- **Bias axis**: no bias vs fixed bias vs learnable bias。

5.2 主结果表最小必要集合

主结果表建议包含：

1. ChromBPNet / 当前 conv-only 强基线；
2. Student TransChromBP（无 distillation）；
3. Student TransChromBP（有 distillation）；

4. Transformer + bias、无 distillation；
5. Transformer + distillation、无 bias；
6. Full flagship：Transformer + distillation + learnable bias；
7. Full flagship：Transformer + distillation + fixed bias。

5.3 解释和分层分析

如果论文要站得住，不能只看 aggregate 指标。至少应补：

- peak / nonpeak 分层结果；
- full output 与 debiased output 的分开评估；
- bias scale / fusion 轨迹；
- locus-level 轨道图；
- 若条件允许，SHAP / motif / MoDISco；
- 若实现成熟，再补 ATAC-specific scorer。

6 这份阶段报告对后续论文的意义

当前结果并不是论文终点，而是论文起点。它们已经帮我们完成了三件关键事情：

1. 确定了一个可信的起始模型主线；
2. 把数据语义问题降级为固定约束，而不是继续做中心矛盾；
3. 证明 bias branch 确实是一个值得保留和分析的任务组件。

因此，后续所有正式实验和写作都应接受同一个判断标准：

> 它是否有助于强化旗舰模型，或者更清楚地解释 Transformer、distillation 与 bias factorization 的关系。

7 关键保留路径

本地报告与骨架

- `reports/transchrombp_tutorial_consolidated_cn.tex`
- `reports/transchrombp_tutorial_consolidated_cn.pdf`
- `reports/transchrombp_paper_outline_cn.tex`
- `reports/transchrombp_paper_outline.tex`
- `reports/transchrombp_project_note_cn.tex`

关键资产目录

- reports/assets/transchrombp_tutorial_test_20260315/
- reports/assets/transchrombp_hybrid_eval_20260315/
- reports/assets/transchrombp_recommended_data_semantics_20260315/

远端冻结快照

- /data1/zhoujiazhen/bylw_atac/TransChromBP/outputs/snapshots/tutorial_report_20260315_fro
- /data1/zhoujiazhen/bylw_atac/TransChromBP/outputs/snapshots/data_semantics_audit_202603

  大权重仍只保留在远端，不下载回本地；本地文档负责描述它们的路径与作用。